Caso de Estudio: Modelado y Generación de Insights en la Industria Azucarera



Curso: Aprendizaje Automático II
Profesor: Anibal Sosa

Fecha de entrega: 22 de noviembre de 2026

Cali, Colombia
2026

Resumen

Este documento describe la fase de modelado predictivo del laboratorio práctico. El objetivo es aplicar técnicas de regresión y clasificación sobre datos históricos de producción de caña de azúcar del Ingenio Providencia. Los estudiantes deberán implementar y validar modelos de machine learning (desde regresión lineal y logística hasta Random Forest y XGBoost), interpretar los resultados desde una perspectiva de negocio y presentar sus hallazgos en un informe técnico estructurado.

Palabras clave: Regresión, Clasificación, Machine Learning, Interpretabilidad, Agricultura de Precisión, Caña de Azúcar

IMPORTANTE: Este taller se debe realizar exclusivamente en grupos de **TRES o CUATRO** personas.
ENTREGA: Domingo 22 de noviembre de 2026
Esta fase del proyecto asume que el Análisis Exploratorio de Datos (EDA) y el preprocesamiento inicial ya han sido completados. El enfoque está en el modelado predictivo y la comunicación de resultados.

1. Alcance del Proyecto: Modelado y Generación de Insights

Esta fase del proyecto se centra exclusivamente en las tareas de modelado predictivo y comunicación de hallazgos. Partiendo del trabajo de preparación de datos (EDA y preprocesamiento), el alcance se limita a los siguientes objetivos:

1. **Modelado Predictivo:** Desarrollar y validar modelos de regresión y clasificación para predecir:
   - **Toneladas de caña por hectárea (TCH)** (HISTORICO SUERTES)
   - **Niveles de desempeño (alto, medio, bajo) para TCH y %Sac.Caña** a partir de variables continuas (BD IPSA 1940).
2. **Generación de Insights:** Interpretar los resultados de los modelos para extraer conclusiones prácticas que apoyen la toma de decisiones en el Ingenio Providencia.
3. **Reporte Técnico:** Elaborar un informe conciso y de alta calidad que comunique la metodología, los resultados y las conclusiones.

2. Modelamiento (Tarea I)

Los estudiantes deberán implementar una estrategia de modelamiento que va de lo simple a lo complejo, permitiendo la comparación y justificación de la selección del mejor modelo.

2.1. Modelos de Referencia (Benchmark)

- **Regresión:** Implementar una *Regresión Lineal Múltiple* para predecir TCH y %Sac.Caña. Analizar la significancia estadística de los coeficientes (p-values), sus signos (positivo/negativo) y magnitud.
- **Clasificación:** Implementar una *Regresión Logística Multinomial* y *K-Vecinos Más Cercanos (KNN)* para clasificar los niveles de TCH y %Sac.Caña. Optimizar el hiperparámetro k para KNN y utilizar regularización (L_1 o L_2) en la regresión logística para analizar la importancia y selección de variables.

2.2. Modelos Avanzados

Para superar el desempeño de los modelos de referencia, implementar y comparar *al menos dos* de los siguientes algoritmos:

- **Random Forest:** Modelo de ensamble basado en árboles de decisión, robusto a outliers y capaz de capturar relaciones no lineales e interacciones complejas.
- **XGBoost (Extreme Gradient Boosting):** Algoritmo de boosting de alto rendimiento que a menudo lidera competencias de machine learning por su precisión y eficiencia.
- **Support Vector Machines (SVM):** Algoritmo efectivo para clasificación, especialmente con kernels no lineales, para encontrar el hiperplano óptimo que separa las categorías.

Justificación: Explicar por qué estos modelos podrían funcionar mejor que la regresión lineal/logística (por ejemplo, porque pueden modelar interacciones complejas entre variables como *lluvias*, *tipo de suelo* y *variedad* que afectan el TCH).

Interpretabilidad: Para modelos de caja negra como Random Forest o XGBoost, utilizar técnicas como *importancia de características (feature importance)* para determinar qué variables son las más influyentes en la predicción, conectando estos hallazgos con el contexto del negocio.

2.3. Validación Rigurosa

- Dividir los datos en *entrenamiento (80 %) y prueba (20 %)* desde el inicio (hold-out validation).
- Para el ajuste de hiperparámetros y la selección de modelos, utilizar *validación cruzada ($k-$fold cross-validation)* con $k = 5$ o $k = 10$, *exclusivamente sobre el conjunto de entrenamiento*. Esto evita el sobreajuste y proporciona una estimación robusta del desempeño del modelo.

3. Reporte de Resultados (Tarea II)

El informe final debe ser un documento técnico de alta calidad, siguiendo una estructura académica estándar. Debe ser claro, conciso (**máximo 5 páginas, excluyendo portada y anexos**) y estar bien estructurado.

3.1. Estructura del Informe

1. **Portada:** Título, nombres de los autores, fecha.

2. **Resumen (Abstract):** Resumen ejecutivo del problema, la metodología empleada y los principales hallazgos (máximo 250 palabras).
3. **Introducción:** Presentar el problema de negocio del Ingenio Providencia, la importancia de predecir TCH y %Sac.Caña, y los objetivos del estudio.
4. **Metodología:**
   - *Datos:* Describir brevemente los datasets y las variables predictoras seleccionadas para los modelos, justificando su inclusión con base en el contexto del negocio.
   - *Estrategia de Modelado:* Detallar los modelos utilizados (benchmark y avanzados), las estrategias de validación (hold-out y validación cruzada) y las métricas de evaluación seleccionadas (R^2, RMSE, MAE para regresión; Accuracy, Precision, Recall, F1-score, Kappa para clasificación).
5. **Resultados y Discusión:** Sección central del informe.
   - Presentar los resultados de forma organizada mediante tablas comparativas del desempeño de todos los modelos.
   - *Interpretar los resultados a la luz del contexto del negocio.* Por ejemplo: ."El modelo XGBoost superó a la regresión lineal con un RMSE de XX, lo que sugiere que las relaciones entre las variables climáticas y el TCH son complejas y no lineales, consistente con lo hallado en la literatura."
   - Incluir *visualizaciones de apoyo:* gráficos de importancia de características, matrices de confusión para clasificación, gráficos de valores reales vs. predichos para regresión.
   - Para regresión lineal, discutir la significancia, signo y magnitud de los coeficientes. Para modelos avanzados, utilizar feature importance para identificar los predictores más relevantes.
6. **Conclusiones:**
   - Resumir los hallazgos clave y la utilidad de los modelos para la toma de decisiones en el Ingenio Providencia.
   - Proponer mejoras concretas: ¿Qué otras variables (datos de sensores, imágenes satelitales) serían útiles? ¿Cómo se podría implementar un sistema de monitoreo en tiempo real? ¿Cuáles son las limitaciones prácticas o éticas de los modelos desarrollados?
7. **Referencias Bibliográficas:** Incluir todas las fuentes citadas en el texto, siguiendo un formato consistente (APA, IEEE, etc.).

Criterios de Evaluación

La evaluación se centrará exclusivamente en las tareas de modelado y comunicación de resultados:

- **Desarrollo y Ajuste de Modelos (40 %):** Correcta implementación de los modelos de referencia (regresión lineal/logística, KNN) y de al menos dos modelos avanzados (Random

Forest, XGBoost o SVM). Uso adecuado de técnicas de ajuste de hiperparámetros (ej. GridSearchCV) con validación cruzada. Cumplimiento riguroso de la división train/test.

- **Validación y Métricas (20 %):** Selección y cálculo apropiado de al menos dos métricas de evaluación: RMSE, MAE, R^2 para regresión; Accuracy, Precision, Recall, F1-Score, kappa y matriz de confusión para clasificación. Comparación clara del desempeño de los modelos mediante tablas o gráficos. Justificación de la selección del "mejor modelo"para cada tarea.
- **Interpretabilidad y Generación de Insights (20 %):** Uso efectivo de técnicas de interpretabilidad (importancia de características, coeficientes de modelos lineales) para explicar las predicciones. Conexión de los hallazgos con el contexto agrícola del Ingenio Providencia, demostrando comprensión de los factores que influyen en TCH y %Sac.Caña.
- **Comunicación de Resultados (20 %):** Informe final claro, conciso y bien estructurado. Comunicación efectiva de la metodología, resultados y conclusiones. Uso apropiado de visualizaciones (gráficos de importancia de características, matrices de confusión, gráficos de valores reales vs. predichos) que respalden la narrativa. El informe no debe contener código.

Entregables

- **Código Fuente:** Archivo Jupyter Notebook (‘.ipynb‘) con la implementación completa del modelado. Debe estar bien documentado y comentado, mostrando claramente el pipeline de modelado (Tarea I). **No incluir el código en el informe.**
- **Informe Final:** Documento en formato PDF (máximo 5 páginas, excluyendo portada y anexos) que detalla la metodología, presenta los resultados de manera organizada, y discute las interpretaciones y conclusiones (Tarea II).

Recomendaciones Finales

- Asegurarse de documentar bien el código y comentar las secciones relevantes para facilitar la comprensión del proceso de modelado.
- Revisar y aplicar los conceptos vistos en clase, especialmente los relacionados con validación cruzada, métricas de evaluación y los modelos.
- Ser críticos en el análisis de resultados y proponer mejoras o futuras líneas de trabajo basadas en los hallazgos obtenidos.
- Organizar el trabajo en equipo de manera eficiente, distribuyendo tareas pero asegurando que todos los miembros comprendan el proceso completo de modelado y los resultados obtenidos.
- Iniciar el trabajo con suficiente antelación para poder abordar todos los puntos con la profundidad requerida.